

PHÂN TÍCH DỮ LIỆU HÀNH VI

Trivago RecSys Challenge 2019

Hành vi quan sát và cấu trúc bài toán xếp hạng khách sạn

Quy mô và đơn vị quan sát

Thành phần	Tổng	Train	Test
User	948.041	730.803	250.852
Items	926.457	872.174	628.837

- Trong file `item_metadata` có 927.142 khách sạn.
- Item được xuất hiện trong train và test có 2 loại: Có trong metadata và ngoài metadata

Vị trí	Tổng	Trong metadata	Ngoài metadata
Tổng	926.457	925.519	938
Train	872.174	860.210	873
Test	628.837	623.768	575



- Event là một dòng hành động; một session có thể gồm nhiều event.
- Mỗi clickout query có danh sách candidate (Khách sạn cân nhắc) riêng để xếp hạng.

Cold start trong bộ dữ liệu Trivago

Hướng kiểm tra:

- User rất ít lịch sử chưa từng xuất hiện trong train và có 1 event trong test và event đó là clickout: 51.114 users
- User có trong train nhưng chỉ có 1 event duy nhất (clickout), ở test cũng tương tự: 908 users


Phân bố loại hành động



Train: **interaction item image** 11.860.750 (74,44%); **clickout item** 1.586.586 (9,96%).


Test: **interaction item image** 2.578.455 (68,17%); **clickout item** 528.779 (13,98%).

Event theo giờ địa phương ước lượng




- Cao nhất là các nước khu Châu Âu (Tây đến Đông Âu). Sau là Nam Mỹ
- Thấp vào giữa đêm (2h) và tăng trở lại đạt đỉnh vào tối (19h)

Clickout theo giờ địa phương ước lượng



- Có tính mùa theo ngày như Event, giống về nhịp và 2 loại đỉnh
- Thu hẹp khoảng cách giữa các nơi, Nam Mỹ kém hơn về chuyển đổi

Độ dài session lệch phải



Tập	P50	P90	P99	Max
Train	4	41	212	3.522
Test	3	31	152	2.815

Lệch phải rất mạnh. Trung bình train 17,50, cao hơn nhiều so với trung vị 4.

Thời lượng session


Thời lượng = timestamp cuối - timestamp đầu, đổi sang giờ.

Tập	Min	P50	P90	P99	Max
Train	0	0,031	0,367	1,370	112,334
Test	0	0,024	0,300	1,232	25,398

P50 khoảng 1,9 phút ở train và 1,4 phút ở test.


Max cách xa P99, cần xem riêng các phiên cực dài (Dấu hiệu outlier).

Số session quan sát trên mỗi user



- Phân phối tập trung ở nhóm một hoặc ít session/user.
- Một nhóm nhỏ có lịch sử nhiều session (3, 4 session/user, chủ yếu ở train).


Thiếu dữ liệu theo cấu trúc action



- **current_filters** (Dành cho hành động có bộ lọc): train 92,76%, test 90,94%.
- **impressions/prices** (Dành cho hành động Click): train 90,04%, test 86,02%.
- **reference** thiếu ở 261.731 event test (253.573 là **clickout** bị che nhãn còn 8.158 thuộc action khác) (6,92%).


Hai mục đầu thiếu do là đặc trưng riêng của hành động. **reference** phần lớn thiếu là có chủ đích - đáp án mà mô hình cần tìm ra.

Nhãn clickout và độ bao phủ candidate





Khách sạn được chọn thuộc danh sách ứng viên có 1.585.837. Còn lại 749 là chọn khách sạn ngoài danh sách.

Quy mô candidate mỗi query



Danh sách ứng viên trải dài đủ các loại số lượng nhưng hầu hết tập chung ở 25 khách sạn/ danh sách.

Tỷ lệ session có clickout theo thiết bị



- Chủ yếu đến từ mobile, ít nhất là tablet. Phân bố không đều.
- Lệch nhau về session nhưng tỉ lệ session chuyển thành Click rất đồng đều.

Step của clickout đầu tiên


Có 309.676 session có click tại step 1.

Đại lượng	Giá trị
Trung vị	2
P90	19
P99	102

$309.676/910.683 = 34,00\%$ trên toàn bộ session train.


Nhiều phiên click sớm, nhưng một nhóm vẫn cần lịch sử dài hơn.

Session đầu tiên có clickout của user




- 717.774/730.803 user train có clickout (98,22%).
- Trong nhóm này, 692.602 user click ở session thứ nhất; 22.524 ở session thứ hai, 2.102 ở session thứ ba.

Độ phủ và độ phong phú metadata



- Metadata: 927.142 item ID, không có ID trùng; tất cả dòng có thuộc tính.
- Phạm vi item được dùng (train + test): 925.519 có metadata, 938 thiếu metadata.
- Property/item: Min = 1; P50 = 15; P90 = 46; P95 = 55; P99 = 71; Max = 112.

Số clickout theo property



- Nhóm >40 property: 798.526 clickout train; nhóm 21-40: 476.526.
- Cột cao chịu ảnh hưởng cả quy mô hiển thị và khuynh hướng lựa chọn.
- Xu hướng người dùng là thiên về minh mạch sản phẩm.

Tiêu chí lựa chọn model

- Được đăng trên tạp chí Q1/Q2
- Có repo công khai từ tác giả
- Thời gian ra mắt trong vòng 5 năm gần đây
- Phù hợp với bộ dữ liệu Trivago (Học được quan hệ về thuộc tính item)

MLEUP

- Đăng trên Knowledge-Based Systems; tạp chí được xếp Q1 trong Scopus năm 2024.
- Paper xuất bản ngày 15/08/2024
- MLEUP có học quan hệ thuộc tính - sản phẩm và thuộc tính trong phiên.
- Có repo công khai

MLEUP tên đầy đủ là Multi perspective Learning for Enhanced User Preferences

Model học từ nhiều góc nhìn để hiểu về người dùng, mô hình thuộc phương pháp session-based recommendation thuộc hướng graph-based/GNN-based

Luồng mô hình

