

Tổng quan mô hình MLEUP và thực nghiệm

Multi-perspective Learning for Enhanced User Preferences

Mục lục

- 1 Tổng quan mô hình
- 2 Thực nghiệm

Mục lục

1 Tổng quan mô hình

2 Thực nghiệm

Hai cách thức của bài toán gợi ý theo phiên

01

Thừa dữ liệu

02

Sở thích phức tạp
và biến đổi

Thách thức 1: Dữ liệu thưa

Vì sao dữ liệu thưa?

Phiên ẩn danh, ngắn

+

Danh sách items dài



Ít tương tác cho mỗi item

Vấn đề: Các phiên dễ gây nhiễu cho nhau

Phiên lịch sử:

Bột mì, hoa, đường, nến → Làm bánh hoa

Phiên hiện tại:

Bóng bay, nến, hoa → Trang trí sự kiện

Nếu chỉ dựa vào mục “hoa” để tìm phiên gần, mô hình có thể đưa bột mì và đường vào sai ngữ cảnh.

Ví dụ trong Trivago

Phiên trung bình: < 4 mục

927, 142 khách sạn

Hệ số Gini = 0,792.

MLEUP xử lý

- Đo độ tương đồng giữa các phiên.
- Tận dụng các thông tin thuộc tính items.

Thách thức 2: Sở thích phức tạp và biến đổi

Cùng một phiên, góc nhìn khác nhau mang ngữ cảnh khác nhau làm hàm ý khác nhau

Ngữ cảnh được xét	Ý định có thể có	Gợi ý hợp lý
Hoa	Trang trí	Bóng bay
Đường + hoa	Làm mứt	Chảo chống dính
Bột mì + đường + hoa	Làm bánh hoa	Lò nướng

Thứ tự cũng quan trọng

TV → Kệ TV → Loa
Thứ tự giúp hệ thống đưa gợi ý từ hành động user

MLEUP xử lý

Dựa vào 2 cách xử lý cấu trúc đề thi:

- **WHGAT – đồng xuất hiện:** học các nhóm khách sạn thường được xem cùng nhau ở nhiều mức độ chi tiết.
- **RPGAT – tuần tự:** học thứ tự chuyển tiếp giữa khách sạn, các quan hệ nhiều bước và vị trí tương đối.

Các hướng nghiên cứu Session-Based Recommendation trước MLEUP

1. Markov, k-NN và mô hình tuyến tính

Khai thác mục lân cận hoặc chuyển tiếp trong phiên.

Hạn chế: khó gán trọng số linh hoạt; dễ bị ảnh hưởng bởi mục gây nhiễu.

2. Attention và RNN

Attention chọn mục liên quan; RNN mã hóa thứ tự phiên.

Hạn chế: attention có thể bỏ qua chuyển tiếp; RNN đơn hướng khó nắm mẫu phức tạp.

3. GNN

Truyền thông tin trên đồ thị để học quan hệ chuyển tiếp phức tạp.

Hạn chế: nhiều mô hình chủ yếu khai thác quan hệ trong phiên hiện tại.

4. Học tự giám sát / tương phản

Tạo tín hiệu học từ các phiên tương tự và không tương tự, hỗ trợ khi dữ liệu thưa.

Thách thức: cần tạo cặp phiên đủ tin cậy để tránh đưa thêm nhiễu.

Ý tưởng kết hợp của MLEUP

MLEUP kết hợp **attention**, **GNN** và **học tương phản**, đồng thời khai thác **thuộc tính khách sạn** và **các phiên liên quan** để học sở thích ổn định và sở thích theo phiên.

1. Đầu vào

- Phiên hiện tại: $S = [v_1, v_2, \dots, v_l]$.
- Thứ tự các mục người dùng đã tương tác.
- Thuộc tính của các mục.
- Các phiên lịch sử liên quan.




2. Mục tiêu đầu ra

- Tính điểm phù hợp cho các mục ứng viên.
- Xếp hạng ứng viên theo khả năng được chọn tiếp theo.
- Đưa mục mục tiêu v_{l+1} lên thứ hạng cao.

Phiên hiện tại + thuộc tính + phiên liên quan $\rightarrow$ xếp hạng mục tiếp theo

Năm thành phần chính của MLEUP



Mục lục

- 1 Tổng quan mô hình
- 2 Thực nghiệm

Chia dữ liệu theo thời gian: tỷ lệ 6:2:2

Phân chia theo session, sau đó tạo các mẫu dự đoán

Tập dữ liệu	Tỷ lệ	Số session	Số mẫu dự đoán
Train	60%	546,409	653,043
Validation	20%	182,137	162,888
Test	20%	182,137	158,517
Tổng	100%	910,683	974,448

Metric đánh giá trong thực nghiệm

Recall@K

$$\text{Recall@K} = \frac{1}{N} \sum_{i=1}^N 1[r_i \leq K]$$

Mục tiêu có nằm trong top-K không?

NDCG@K

$$\text{NDCG@K} = \frac{1}{N} \sum_{i=1}^N \frac{1[r_i \leq K]}{\log_2(r_i + 1)}$$

Mục tiêu được xếp cao đến đâu?

Trivago: Bổ sung thông tin hành động

Cách mã hóa action_type

Loại hành động tại mỗi bước



ID hành động → **Action Embedding**



GRU

Học chuỗi hành động theo thời gian



Ghép với **biểu diễn item sau đồ thị**
và **vector vị trí**

Thông tin được bổ sung

Mỗi bước cho biết:

- Người dùng tương tác với khách sạn nào.
- Thực hiện loại hành động gì.
- Hành động nằm ở đâu trong chuỗi.

Ví dụ chuỗi lịch sử

H_1 : xem ảnh → H_1 : xem thông tin → H_2 : checkout

Cùng H_1 , hai hành động tạo ra tín hiệu hành vi khác nhau.

Trivago: Tinh gọn metadata còn 53 trường

Cấu trúc metadata

3 trường phân loại

Hạng sao
Ngưỡng sao
Mức đánh giá

+

50 thuộc tính nhị phân

Mỗi thuộc tính được mã hóa:
1: có ghi nhận; 0: không ghi nhận.

↓

53 trường cho mỗi khách sạn

Cách chọn 50 thuộc tính

- 1 Lấy các sự kiện filter selection trong **tập train**.
- 2 Đối chiếu tên bộ lọc với thuộc tính khách sạn.
- 3 Đếm số lần mỗi thuộc tính được chọn làm bộ lọc.
- 4 Giữ **50 thuộc tính** có tần suất cao nhất.

Mục đích

Giảm bộ nhớ và chi phí xử lý metadata; ưu tiên các thuộc tính người dùng thường dùng để lọc khách sạn.

Kết quả thực nghiệm trên Trivago

So sánh tại epoch 1 trên tập validation

Lần chạy	Batch	Epoch	MRR	Hit@20	NDCG@20
Colab	4000	1	0.2233	0.8746	0.3592
Kaggle + Action	256	1	0.3563	0.9289	0.4805


Nhận xét

Bản Kaggle có Action Embedding + GRU đạt cả ba metric cao hơn tại epoch 1.

Bản Colab đạt MRR cao nhất trong log là **0.3051** tại epoch 6.


Chọn ngưỡng cắt metadata

50 thuộc tính được chọn theo tần suất bộ lọc



50 thuộc tính xếp theo số lượt chọn trong train.

Phân bố bộ lọc và mức bao phủ khi giảm số trường



Quyết định

Giữ top-15 thuộc tính nhị phân theo tần suất.
15 thuộc tính nhị phân + 3 trường phân loại = **18 trường metadata tổng.**

Kết quả lần chạy gần nhất

Cấu hình lần chạy

Batch size = 256

Metric	Epoch 1 – Validation
NDCG@5	0.3747
Recall@5	0.5276