

Tổng quan mô hình MLEUP và thực nghiệm

Multi-perspective Learning for Enhanced User Preferences

Mục lục

- 1 Tổng quan mô hình
- 2 Thực nghiệm

Mục lục

1 Tổng quan mô hình

2 Thực nghiệm

Hai cách thức của bài toán gợi ý theo phiên

01

Thừa dữ liệu

02

Sở thích phức tạp
và biến đổi

Thách thức 1: Dữ liệu thưa

Vì sao dữ liệu thưa?

Phiên ẩn danh, ngắn

+

Danh sách items dài



Ít tương tác cho mỗi item

Vấn đề: Các phiên dễ gây nhiễu cho nhau

Phiên lịch sử:

Bột mì, hoa, đường, nến → Làm bánh hoa

Phiên hiện tại:

Bóng bay, nến, hoa → Trang trí sự kiện

Nếu chỉ dựa vào mục “hoa” để tìm phiên gần, mô hình có thể đưa bột mì và đường vào sai ngữ cảnh.

Ví dụ trong Trivago

Phiên trung bình: < 4 mục

927, 142 khách sạn

Hệ số Gini = 0,792.

MLEUP xử lý

- Đo độ tương đồng giữa các phiên.
- Tận dụng các thông tin thuộc tính items.

Thách thức 2: Sở thích phức tạp và biến đổi

Cùng một phiên, góc nhìn khác nhau mang ngữ cảnh khác nhau làm hàm ý khác nhau

Ngữ cảnh được xét	Ý định có thể có	Gợi ý hợp lý
Hoa	Trang trí	Bóng bay
Đường + hoa	Làm mứt	Chảo chống dính
Bột mì + đường + hoa	Làm bánh hoa	Lò nướng

Thứ tự cũng quan trọng

TV → Kệ TV → Loa
Thứ tự giúp hệ thống đưa gợi ý từ hành động user

MLEUP xử lý

Dựa vào 2 cách xử lý cấu trúc đề thi:

- **WHGAT – đồng xuất hiện:** học các nhóm khách sạn thường được xem cùng nhau ở nhiều mức độ chi tiết.
- **RPGAT – tuần tự:** học thứ tự chuyển tiếp giữa khách sạn, các quan hệ nhiều bước và vị trí tương đối.

Các hướng nghiên cứu Session-Based Recommendation trước MLEUP

1. Markov, k-NN và mô hình tuyến tính

Khai thác mục lân cận hoặc chuyển tiếp trong phiên.

Hạn chế: khó gán trọng số linh hoạt; dễ bị ảnh hưởng bởi mục gây nhiễu.

2. Attention và RNN

Attention chọn mục liên quan; RNN mã hóa thứ tự phiên.

Hạn chế: attention có thể bỏ qua chuyển tiếp; RNN đơn hướng khó nắm mẫu phức tạp.

3. GNN

Truyền thông tin trên đồ thị để học quan hệ chuyển tiếp phức tạp.

Hạn chế: nhiều mô hình chủ yếu khai thác quan hệ trong phiên hiện tại.

4. Học tự giám sát / tương phản

Tạo tín hiệu học từ các phiên tương tự và không tương tự, hỗ trợ khi dữ liệu thưa.

Thách thức: cần tạo cặp phiên đủ tin cậy để tránh đưa thêm nhiễu.

Ý tưởng kết hợp của MLEUP

MLEUP kết hợp **attention**, **GNN** và **học tương phản**, đồng thời khai thác **thuộc tính khách sạn** và **các phiên liên quan** để học sở thích ổn định và sở thích theo phiên.

1. Đầu vào

- Phiên hiện tại: $S = [v_1, v_2, \dots, v_l]$.
- Thứ tự các mục người dùng đã tương tác.
- Thuộc tính của các mục.
- Các phiên lịch sử liên quan.




2. Mục tiêu đầu ra

- Tính điểm phù hợp cho các mục ứng viên.
- Xếp hạng ứng viên theo khả năng được chọn tiếp theo.
- Đưa mục mục tiêu v_{l+1} lên thứ hạng cao.

Phiên hiện tại + thuộc tính + phiên liên quan $\rightarrow$ xếp hạng mục tiếp theo

Năm thành phần chính của MLEUP



Session Group Construction (Xây các nhóm Session)

Công thức chính

$$\text{Sim}(S, T) = \text{Ov}(S, T) - \text{In}(S, T)$$

- Ov : mức trùng lặp item.
- In : tỷ lệ cặp item không tương thích.

Quan hệ không tương thích

Một cặp item thỏa mãn hai điều kiện:

- Chưa từng cùng phiên ($p_{ij} = 0$); ví dụ: hai khách sạn ở hai nước.
- Cùng thường xuất hiện với item thứ ba k ($p_{ik}, p_{jk} \geq \mu$).

Ví dụ minh họa

Phiên hiện tại: $S = [A, B, C]$

Hai phiên lịch sử:

$$T_1 = [A, B, D], \quad T_2 = [A, E, F]$$

Giả sử C, D không đồng xuất hiện ($p_{CD} = 0$) và cùng thường xuất hiện với item K ($p_{CK}, p_{DK} \geq \mu$).


- $\text{Ov} = 2/3$
- $\text{In} = 1/9$

$$\text{Sim}(S, T_1) = \frac{2}{3} - \frac{1}{9} = \frac{5}{9} \approx 0.56$$

$$\text{Sim}(S, T_2) = \frac{1}{3} - 0 \approx 0.33$$


Đầu ra: Nhóm phiên của S chọn $G_S = \{T_1\}$, vì T_1 có điểm tương đồng cao hơn.

Attribute Embedding Learning: Thuộc tính-item




Mô hình gán trọng số cho các khách sạn theo từng thuộc tính, sau đó ghép các embedding thuộc tính để tạo vector metadata cho mỗi khách sạn.

Attribute Embedding Learning: Thuộc tính trong phiên




Giúp khách sạn nhận thêm ngữ cảnh từ những khách sạn khác trong cùng phiên. Nhờ vậy, mô hình học được các thuộc tính nào thường đi cùng nhau trong hành vi xem, thay vì hiểu từng khách sạn riêng lẻ.

Item Embeddings Learning: Hai nhánh quan hệ




WHGAT: Quan hệ đồng xuất hiện




Trong mỗi nhóm, attention chọn khách sạn đóng góp nổi bật.
Với mỗi khách sạn, attention tổng hợp thông tin từ các nhóm chứa nó.

RPGAT: Quan hệ tuần tự bậc cao




Với mỗi khách sạn, RPGAT xét các khách sạn đứng trước và sau nó. Attention xác định láng giềng nào đóng góp nhiều, đồng thời giữ thông tin về hướng và khoảng cách trong phiên.

User Preferences Extraction: Trích xuất sở thích




User Preferences Fusion: Hợp nhất sở thích



Ví dụ Trivago: sở thích về thành phố và hạng sao được kết hợp với mỗi quan tâm thể hiện trong phiên hiện tại để xếp hạng khách sạn phù hợp hơn.

Multi-task Joint Training: Huấn luyện đa nhiệm



λ điều chỉnh mức đóng góp của nhiệm vụ tự giám sát.

Mục lục

1 Tổng quan mô hình

2 Thực nghiệm

Metric đánh giá trong thực nghiệm

Recall@K

$$\text{Recall@K} = \frac{1}{N} \sum_{i=1}^N 1[r_i \leq K]$$

Mục tiêu có nằm trong top-K không?

NDCG@K

$$\text{NDCG@K} = \frac{1}{N} \sum_{i=1}^N \frac{1[r_i \leq K]}{\log_2(r_i + 1)}$$

Mục tiêu được xếp cao đến đâu?

Trivago: Bổ sung thông tin hành động

Cách mã hóa action_type

Loại hành động tại mỗi bước



ID hành động → **Action Embedding**



GRU

Học chuỗi hành động theo thời gian



Ghép với **biểu diễn item sau đồ thị**
và **vector vị trí**

Thông tin được bổ sung

Mỗi bước cho biết:

- Người dùng tương tác với khách sạn nào.
- Thực hiện loại hành động gì.
- Hành động nằm ở đâu trong chuỗi.

Ví dụ chuỗi lịch sử

H_1 : xem ảnh → H_1 : xem thông tin → H_2 : checkout

Cùng H_1 , hai hành động tạo ra tín hiệu hành vi khác nhau.

Trivago: Tinh gọn metadata còn 53 trường

Cấu trúc metadata

3 trường phân loại

Hạng sao
Ngưỡng sao
Mức đánh giá

+

50 thuộc tính nhị phân

Mỗi thuộc tính được mã hóa:
1: có ghi nhận; 0: không ghi nhận.

↓

53 trường cho mỗi khách sạn

Cách chọn 50 thuộc tính

- 1 Lấy các sự kiện filter selection trong **tập train**.
- 2 Đối chiếu tên bộ lọc với thuộc tính khách sạn.
- 3 Đếm số lần mỗi thuộc tính được chọn làm bộ lọc.
- 4 Giữ **50 thuộc tính** có tần suất cao nhất.

Mục đích

Giảm bộ nhớ và chi phí xử lý metadata; ưu tiên các thuộc tính người dùng thường dùng để lọc khách sạn.

Kết quả thực nghiệm trên Trivago

So sánh tại epoch 1 trên tập validation

Lần chạy	Batch	Epoch	MRR	Hit@20	NDCG@20
Colab	4000	1	0.2233	0.8746	0.3592
Kaggle + Action	256	1	0.3563	0.9289	0.4805

Nhận xét

Bản Kaggle có Action Embedding + GRU đạt cả ba metric cao hơn tại epoch 1.

Bản Colab đạt MRR cao nhất trong log là **0.3051** tại epoch 6.