BÁO CÁO TỔNG HỢP RECOMMENDATION

Gợi ý khách sạn theo phiên trên dữ liệu Trivago

Mô hình MLEUP, đồ thị hành vi
và giá tương đối

Đào Trung Hiếu

Nội dung trình bày

01 Tổng quan bài toán

02 Dữ liệu và phân tích khám phá

03 Phương pháp MLEUP và các cải tiến

04 Thực nghiệm và kết luận

Mục lục

01 Tổng quan bài toán

02 Dữ liệu và phân tích khám phá

03 Phương pháp MLEUP và các cải tiến

04 Thực nghiệm và kết luận

Recommendation và Next Best Product

Nên gợi ý sản phẩm nào cho người dùng lúc này?

Recommendation

Lựa chọn và xếp hạng sản phẩm theo mức độ phù hợp với người dùng.

Next Best Product

Đề xuất lựa chọn tiếp theo phù hợp với **nhu cầu tại một thời điểm**.

Ứng dụng trong đề tài: **gợi ý khách sạn theo phiên**.

Mục tiêu và phạm vi đề tài

Mục tiêu

Xếp hạng khách sạn theo khả năng người dùng sẽ **clickout**.

Thông tin khai thác

- Lịch sử tương tác trong phiên (VD: Xem ảnh, thông tin,... của item).
- Thuộc tính khách sạn.
- Danh sách ứng viên.

Phạm vi dự đoán

- Khách sạn cụ thể.
- Xếp hạng trong impressions.
- Nhãn: `clickout item`.

Mục tiêu quan sát là clickout; dữ liệu không cung cấp nhãn xác nhận đặt phòng.

Lựa chọn bộ dữ liệu Trivago

Đối tượng dự đoán

Dữ liệu	Đối tượng
Airbnb	Quốc gia đặt chỗ đầu tiên
Expedia	Nhóm khách sạn
Trivago	**Khách sạn được clickout**

Lý do lựa chọn

- Dữ liệu thuộc loại theo phiên (session).
- Chuỗi hành vi có thứ tự.
- Metadata và tập ứng viên.

Trivago phù hợp với bài toán.

Phát biểu bài toán

Đầu vào

Lịch sử trước clickout:

Các `action_type` nằm trước clickout

Tập ứng viên:

$$C_t = \{H_1, H_2, H_3, H_4\}$$

Tập thuộc tính:

$$\mathbf{x}_i = [x_{i1}, x_{i2}, \ldots, x_{im}]$$

$\mathbf{x}_i$ là vector metadata của khách sạn H_i.

Đầu ra minh họa

Danh sách khách sạn đã xếp hạng.

$$[H_2,\ H_1,\ H_4,\ H_3]$$

Top-1: H_2

Mục tiêu

Đưa khách sạn thực sự được clickout lên **vị trí cao**.

Mục lục

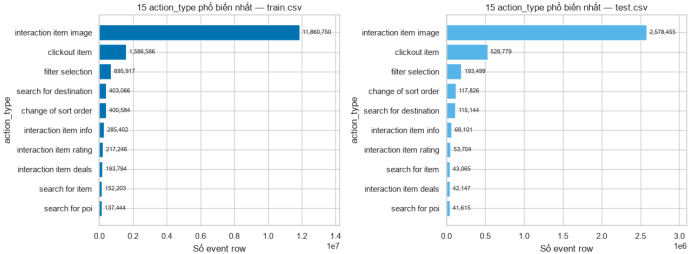
01 Tổng quan bài toán

02 Dữ liệu và phân tích khám phá

03 Phương pháp MLEUP và các cải tiến

04 Thực nghiệm và kết luận

Hành vi trong phiên và tín hiệu dự đoán



Biểu đồ gốc từ Trivago_EDA_slides.zip. Mỗi dòng dữ liệu là một event.

Train gốc

15,93 triệu event

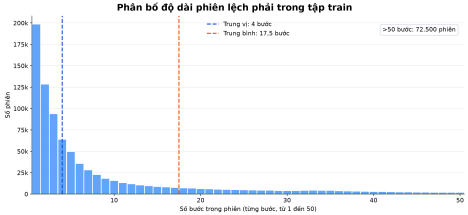
910.683 session

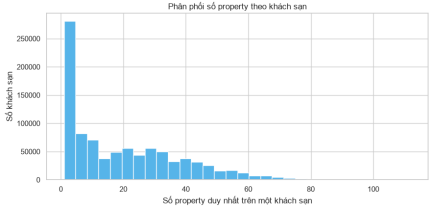
10 loại hành động

Ý nghĩa đối với mô hình

Xem ảnh chiếm **74,44%** event train. Cùng một khách sạn có thể xuất hiện với **nhiều loại tương tác**.

Phiên ngắn và metadata phong phú





Lịch sử hạn chế

71,6% phiên có tối đa 10 bước tương tác.
Trung vị: **4 bước/phiên**.

Thông tin bổ trợ

927.142 khách sạn trong catalog.
Trung vị: **15 property/khách sạn**.

Phiên ngắn cung cấp ít tín hiệu tương tác; mô hình học kết hợp **quan hệ item với thuộc tính khách sạn** để xếp hạng ứng viên.

Mục lục

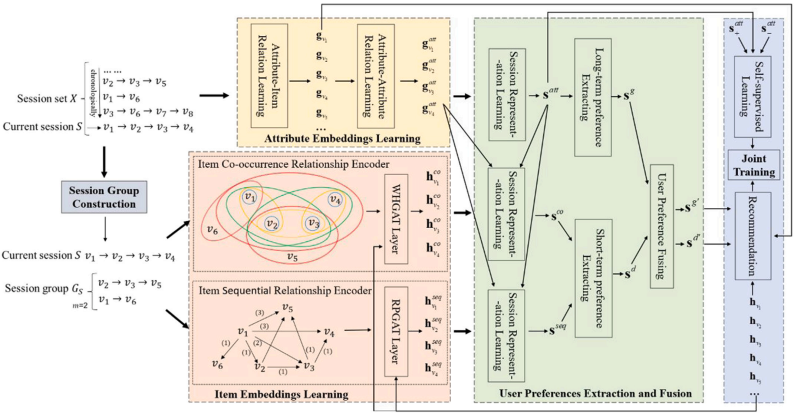
01 Tổng quan bài toán

02 Dữ liệu và phân tích khám phá

03 Phương pháp MLEUP và các cải tiến

04 Thực nghiệm và kết luận

Kiến trúc tổng quan MLEUP



Zhang và cộng sự, Knowledge-Based Systems 298 (2024)

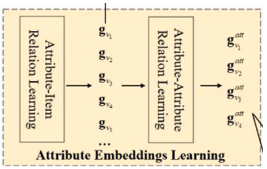
Nhóm phiên liên quan và học thuộc tính

Chọn các phiên có liên quan

$$\mathrm{Sim}(S, S') = \mathrm{Ov}(S, S') - \mathrm{In}(S, S')$$

- Ov: mức trùng lặp item.
- In: mức không tương thích.

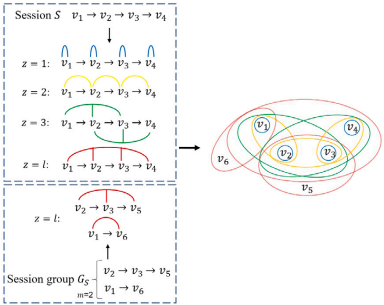
Mục đích: bổ sung tín hiệu và giảm nhiễu.



Hai quan hệ thuộc tính

- **Thuộc tính–item**: các item cùng giá trị thuộc tính.
- **Thuộc tính–thuộc tính**: self-attention trong phiên.

WHGAT: quan hệ đồng xuất hiện đa mức



Hình gốc: MLEUP, Fig. 2. Một hyperedge có thể nối nhiều item.

Xây dựng hypergraph (Siêu cạnh)

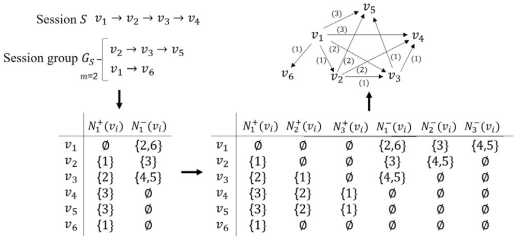
- Trượt cửa sổ với nhiều độ dài trên phiên hiện tại.
- Bổ sung siêu cạnh từ các phiên liên quan.
- Gán trọng số cho các siêu cạnh.

Hai bước truyền thông tin

1. Item → siêu cạnh: Attention tổng hợp biểu diễn của các item.

2. Siêu cạnh → item: Attention kết hợp trọng số siêu cạnh để cập nhật biểu diễn item.

RPGAT: quan hệ tuần tự và vị trí tương đối



	$N_1^+(v_i)$	$N_1^-(v_i)$
v_1	$\emptyset$	{2,6}
v_2	{1}	{3}
v_3	{2}	{4,5}
v_4	{3}	$\emptyset$
v_5	{3}	$\emptyset$
v_6	{1}	$\emptyset$

	$N_1^+(v_i)$	$N_2^+(v_i)$	$N_3^+(v_i)$	$N_1^-(v_i)$	$N_2^-(v_i)$	$N_3^-(v_i)$
v_1	$\emptyset$	$\emptyset$	$\emptyset$	{2,6}	{3}	{4,5}
v_2	{1}	$\emptyset$	$\emptyset$	{3}	{4,5}	$\emptyset$
v_3	{2}	{1}	$\emptyset$	{4,5}	$\emptyset$	$\emptyset$
v_4	{3}	{2}	{1}	$\emptyset$	$\emptyset$	$\emptyset$
v_5	{3}	{2}	{1}	$\emptyset$	$\emptyset$	$\emptyset$
v_6	{1}	$\emptyset$	$\emptyset$	$\emptyset$	$\emptyset$	$\emptyset$

Ví dụ khoảng cách

Trong chuỗi $[H_1, H_2, H_3]$, H_3 nằm sau H_1 hai bước. RPGAT sử dụng cả hướng và khoảng cách này để mô hình hóa quan hệ.

Thông tin cần giữ

- Thứ tự trước–sau giữa các item.
- Quan hệ giữa các item cách nhau nhiều bước.
- Vị trí tương đối của item lân cận.

Cách học

- Kết hợp item và vị trí tương đối.
- Attention tổng hợp theo từng hướng.
- Highway cập nhật biểu diễn item.

Kết hợp sở thích và huấn luyện chung

Sở thích từ thuộc tính

Attention trọng số α trên metadata tạo s^g.

Bổ sung mục tiêu học tương phản.

Sở thích từ quan hệ item

Đồng xuất hiện tạo s^{co}; tuần tự tạo s^{seq}.

Gate kết hợp hai nhánh thành s^d.

Chấm điểm và tối ưu

Co-guided fusion kết hợp hai nguồn sở thích $\rightarrow \widetilde{s}^g, \widetilde{s}^d$.

Điểm xếp hạng

$$z(v) = \widetilde{s}^{g\top} g_v + \widetilde{s}^{d\top} h_v$$

g_v	Biểu diễn thuộc tính của khách sạn ứng viên v.
h_v	Biểu diễn quan hệ item của khách sạn ứng viên v.

Hàm huấn luyện

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda \mathcal{L}_{\text{SSL}}$$

$\mathcal{L}_{\text{rec}}$	Loss học dự đoán item mục tiêu.
$\mathcal{L}_{\text{SSL}}$	Loss tương phản hỗ trợ học biểu diễn thuộc tính.
λ	Trọng số điều chỉnh mức đóng góp của loss SSL.

Hai cải tiến mô hình và tinh gọn metadata

	Thay đổi	Vai trò
Cải tiến 1	Đồ thị sự kiện + attention theo ứng viên	Phân biệt hành động; đọc lịch sử riêng cho từng khách sạn
Cải tiến 2	Nhánh giá tương đối có gate	Điều chỉnh điểm theo giá trong danh sách đang hiển thị
Giảm trường	Metadata: $53 \rightarrow 18$	Giữ 15 thuộc tính nhị phân + 3 trường phân loại

Kết hợp trên nền MLEUP

$$z(v) = z_{\text{base}}(v) + \Delta z_{\text{event}}(v) + \Delta z_{\text{price}}(v)$$

Cải tiến 1: đồ thị sự kiện theo ứng viên

Biểu diễn sự kiện

Mỗi nút là một lần tương tác:

$$u_t = \tanh(W[h_t^{seq} \| p_t \| E(a_t)])$$

- h_t^{seq}: biểu diễn khách sạn sau RPGAT.
- p_t: vector vị trí sự kiện.
- $E(a_t)$: vector loại hành động.

Kết nối và truyền thông tin

- Cạnh thời gian: hai sự kiện kề nhau.
- Cạnh lặp: các sự kiện cùng khách sạn.

Mỗi ứng viên đọc lịch sử riêng

1. Query: kết hợp item và metadata.

$$q_v = \tanh(W_q[h_v \| g_v])$$

2. Attention: mức liên quan với từng sự kiện.

$$\alpha_{vt} = \mathrm{softmax}_t\left(\frac{q_v^\top W_k \widehat{u}_t}{\sqrt{d}}\right)$$

3. Ngữ cảnh: tổng hợp theo attention.

$$c_v = \sum_t \alpha_{vt} W_v \widehat{u}_t$$

4. Điều chỉnh điểm: kết hợp query và ngữ cảnh.

$$\Delta z_{\text{event}}(v) = \mathrm{MLP}([q_v \| c_v])$$

Cải tiến 2: giá tương đối và điều chỉnh điểm

9 đặc trưng giá cho mỗi ứng viên

5 về giá	Giá chuẩn hóa, thứ hạng, so với trung vị và giá thấp nhất, độ phân tán.
2 độ phủ	Số lượng và tỷ lệ giá hợp lệ trong danh sách.
2 cờ	Ứng viên có giá hợp lệ; danh sách có ít nhất hai giá hợp lệ.

Tạo điểm điều chỉnh theo giá

Với khách sạn ứng viên v:

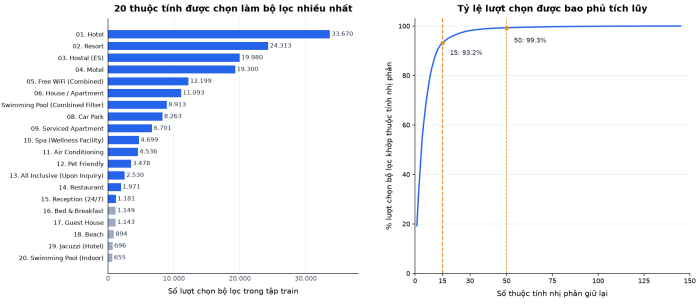
$$\Delta z_{\text{price}}(v) = m_v \, \gamma \, f_v$$

Δz_{price}	Điểm điều chỉnh theo giá.
m_v	1 nếu giá hợp lệ; 0 nếu thiếu hoặc không hợp lệ.
γ	Gate theo phiên, từ 0 đến 1, điều tiết ảnh hưởng của giá.
f_v	Điểm MLP từ giá, thông tin khách sạn và sở thích phiên.

MLP tính f_v riêng cho từng ứng viên; $\gamma(s)$ dùng chung cho cả phiên.

Tham số của MLP và gate cùng được học qua loss xếp hạng clickout.

Tinh gọn metadata: từ 53 xuống 18 trường



Mẫu số tích lũy: 174.779 lượt chọn khớp thuộc tính nhị phân trong train. Không phải độ chính xác model.

Cách chọn

Đếm `filter selection` trong **train**; khớp tên property; giữ top-15.

Cấu trúc cuối

3 trường phân loại + 15 nhị phân.
18 trường metadata/khách sạn.

Mục lục

01 Tổng quan bài toán

02 Dữ liệu và phân tích khám phá

03 Phương pháp MLEUP và các cải tiến

04 Thực nghiệm và kết luận

Tiền xử lý và chia dữ liệu theo thời gian

Làm sạch và tạo mẫu

Lọc nhãn ngoài catalog/impressions; chuẩn hóa phiên; chia theo thời gian rồi tạo mẫu.

Tập	Tỷ lệ	Số session	Số mẫu	Bắt đầu	Kết thúc	Thời lượng
Train	60%	439.882	689.689	01/11 07:00	05/11 02:37	3 ngày 19 tiếng
Validation	20%	146.628	184.103	05/11 02:37	06/11 04:39	1 ngày 2 tiếng
Test	20%	146.628	182.323	06/11 04:39	07/11 06:59	1 ngày 2 tiếng
Tổng	100%	733.138	1.056.115	01/11 07:00	07/11 06:59	6 ngày

Chỉ dùng **tiền tố lịch sử** trước clickout cần dự đoán.

Đánh giá khả năng xếp hạng

Recall@5

$$\frac{1}{N}\sum_{i=1}^{N}\mathbf{1}[r_i \le 5]$$

Mục tiêu có nằm trong top-5?

NDCG@5

$$\frac{1}{N}\sum_{i=1}^{N}\frac{\mathbf{1}[r_i \le 5]}{\log_2(r_i+1)}$$

Mục tiêu đứng cao đến đâu?

Ví dụ: một mục tiêu ở hạng 3

Recall@5 $= 1$; NDCG@5 $= 1/\log_2(4) = 0{,}5$.

r_i là thứ hạng mục tiêu.

Kết quả các cấu hình cải tiến

Cấu hình MLEUP	Epoch	Thời gian	NDCG@5	Recall@5
MLEUP – 53 trường	1	9 tiếng	0.2233	0.5746
MLEUP – 18 trường	1	1,5 tiếng	0.3807	0.5380
MLEUP 18 trường + cải tiến 1	1	1,5 tiếng	0.6002	0.6743
MLEUP 18 trường + cải tiến 1 + 2	1	1,5 tiếng	0.6135	0.6935

Cải tiến 1: Đồ thị sự kiện và attention theo ứng viên.

Cải tiến 2: Giá tương đối và điều chỉnh điểm ứng viên.

Hai baseline để đối chiếu

GRU4Rec: học tuần tự

1. Embedding chuỗi item.
2. GRU cập nhật trạng thái phiên.
3. Chấm điểm item tiếp theo.

SKNN: khai thác phiên tương tự

1. Tìm phiên train có item trùng.
2. Chọn k phiên tương tự.
3. Tổng hợp điểm cho item gợi ý.

Hai baseline dùng **item**; cấu hình trình bày không dùng action hay metadata.

So sánh MLEUP với baseline

Mô hình	NDCG@5	Recall@5
MLEUP 18 trường + cải tiến 1 + 2	0.6231	0.7027
GRU4Rec	0.5529	0.6366
SKNN	0.6047	0.7175

Cải tiến 1: Đồ thị sự kiện và attention theo ứng viên.
Cải tiến 2: Giá tương đối và điều chỉnh điểm ứng viên.

Tài liệu tham khảo

[1] L. Zhang, D. Shen, Y. Kou và T. Nie.
Multi-perspective learning for enhanced user preferences for session-based recommendation.
Knowledge-Based Systems, 298, 111997, 2024.
DOI: 10.1016/j.knosys.2024.111997.

[2] B. Hidasi, A. Karatzoglou, L. Baltrunas và D. Tikk.
Session-based Recommendations with Recurrent Neural Networks.
ICLR, 2016. arXiv:1511.06939.

[3] D. Jannach và M. Ludewig.
When Recurrent Neural Networks Meet the Neighborhood for Session-Based Recommendation.
ACM RecSys, tr. 306–310, 2017. DOI: 10.1145/3109859.3109872.

[4] RecSys Challenge 2019.
Problem Definition and Dataset Documentation: Session-based Hotel Recommendation.
Tài liệu chính thức: bài toán, hành động, impressions, prices và metadata.